

Điều chỉnh năm thuật toán lấy mẫu trên Đồ thị Tri thức Mờ để đảm bảo tính chất Submodular

Nguyên tắc chung của việc điều chỉnh

Cả năm thuật toán lấy mẫu (2.3, 2.5, 2.6, 2.7, 2.8) đều được đánh giá bởi hàm đại diện Rep, vốn đã được chứng minh là hàm *đơn điệu* và *dưới mô-đun* (submodular) trên toàn bộ 2^R (Định lý 4 trong khung lý thuyết) — đây là tính chất **nội tại của bản thân hàm** Rep, đúng với mọi tập con $S \subseteq R$ bất kể S được tạo ra bằng cách nào. Do đó, câu hỏi " $\tilde{R}$ có thỏa submodular không" luôn có câu trả lời tầm thường là *có*.

Vấn đề thực chất cần xét là: **thuật toán có kế thừa được bảo chứng xấp xỉ $(1 - 1/e)$ của Định lý 5 (Nemhauser) hay không**. Điều này chỉ đúng khi thuật toán thỏa *đồng thời* hai điều kiện:

- (i) Tại mỗi bước, phần tử được chọn phải là $\arg \max$ lợi ích biên $\Delta(r) = \text{Rep}(\tilde{R} \cup \{r\}) - \text{Rep}(\tilde{R})$, tính trên **toàn bộ** tập ứng viên còn lại (không giới hạn bởi vị trí, kết nối đồ thị, hay quy tắc ngẫu nhiên);
- (ii) Mỗi bước chỉ thêm đúng **một** phần tử duy nhất vào tập đang xây dựng.

Rà soát năm thuật toán gốc cho thấy **không thuật toán nào** thỏa cả hai điều kiện trên — mỗi thuật toán vi phạm theo cách riêng (chọn ngẫu nhiên, giới hạn theo vị trí/thứ tự, giới hạn theo kết nối đồ thị, hoặc kiểm tra trùng lặp chỉ cục bộ). Phần dưới đây trình bày phương án sửa (Phương án A: chuyển về cơ chế tham lam tất định) cho từng thuật toán, cùng lý lẽ bảo chứng tương ứng.

Thuật toán gốc	Sau khi sửa (Phương án A)	Cơ sở bảo chứng
2.3 - Ngẫu nhiên có chủ đích	Trùng GreedyFKGS	Định lý 5
2.5 - Phân tầng	Giữ cấu trúc tầng, sửa chọn nội bộ	Định lý 5 + Định lý 7
2.6 - Hệ thống	Trùng GreedyFKGS	Định lý 5
2.7 - Gom cụm	Giữ cấu trúc cụm, sửa chọn nội bộ	Định lý 5 + Định lý 7
2.8 - Quả cầu tuyết	Trùng GreedyFKGS	Định lý 5

Nhận xét chung: chỉ các thuật toán có cấu trúc *phân hoạch tường minh, rời nhau, phủ kín* R (2.5, 2.7) mới giữ được đặc trưng thiết kế riêng sau khi sửa, nhờ tái sử dụng được Định lý 7 (Stratified Greedy) — một định lý về phân hoạch tổng quát, không phụ thuộc tiêu chí phân hoạch cụ thể là "tầng" hay "cụm". Các thuật toán còn lại (2.3, 2.6, 2.8), dựa trên ràng buộc thứ tự/vị trí/kết nối cục bộ vốn xung khắc với tầm nhìn toàn cục của $\arg \max \Delta$, buộc phải đánh đổi hoàn toàn đặc trưng riêng để đổi lấy bảo chứng lý thuyết.

Bổ đề chuẩn bị (dùng chung cho cả năm chứng minh)

Bổ đề 1 (Đẳng thức lợi ích biên qua bảng Cov). *Giả sử một thuật toán duy trì bảng Cov trên một tập nền Ω (có thể là R , một tầng R^s , hay một cụm C_i) theo đúng quy tắc: khởi tạo $\text{Cov}(x) = 0$ với mọi $x \in \Omega$, và sau mỗi lần thêm phần tử y vào tập đang xây dựng S , cập nhật $\text{Cov}(x) \leftarrow \max(\text{Cov}(x), \text{Sim}(x, y))$ với mọi $x \in \Omega$. Khi đó, tại mọi thời điểm, bất biến sau luôn đúng:*

$$\text{Cov}(x) = \max_{s \in S} \text{Sim}(x, s), \quad \forall x \in \Omega$$

(quy ước $\max_\emptyset = 0$). Hệ quả: với mọi ứng viên $r \notin S$,

$$\Delta(r) := \frac{1}{|\Omega|} \sum_{x \in \Omega} [\max(\text{Cov}(x), \text{Sim}(x, r)) - \text{Cov}(x)] = \text{Rep}_\Omega(S \cup \{r\}) - \text{Rep}_\Omega(S),$$

trong đó $\text{Rep}_\Omega(S) := \frac{1}{|\Omega|} \sum_{x \in \Omega} \max_{s \in S} \text{Sim}(x, s)$.

Proof. Quy nạp theo số phần tử đã thêm vào S . Cơ sở: $S = \emptyset \Rightarrow \text{Cov} \equiv 0 = \max_\emptyset \text{Sim}(x, \cdot)$, đúng theo quy ước. Bước quy nạp: giả sử bất biến đúng ngay trước khi thêm y , tức $\text{Cov}(x) = \max_{s \in S} \text{Sim}(x, s)$. Sau khi cập nhật $\text{Cov}(x) \leftarrow \max(\text{Cov}(x), \text{Sim}(x, y)) = \max(\max_{s \in S} \text{Sim}(x, s), \text{Sim}(x, y)) = \max_{s \in S \cup \{y\}} \text{Sim}(x, s)$, đúng bất biến cho $S \cup \{y\}$. Theo nguyên lý quy nạp, bất biến đúng tại mọi bước.

Từ bất biến, với $r \notin S$: $\max(\text{Cov}(x), \text{Sim}(x, r)) = \max(\max_{s \in S} \text{Sim}(x, s), \text{Sim}(x, r)) = \max_{s \in S \cup \{r\}} \text{Sim}(x, s)$. Thay vào định nghĩa $\Delta(r)$:

$$\Delta(r) = \frac{1}{|\Omega|} \sum_{x \in \Omega} \left[\max_{s \in S \cup \{r\}} \text{Sim}(x, s) - \max_{s \in S} \text{Sim}(x, s) \right] = \text{Rep}_\Omega(S \cup \{r\}) - \text{Rep}_\Omega(S). \quad \square$$

Nhận xét 1. Bổ đề 1 là hình thức hoá lại của Bổ đề 2 (tính tương đương giữa Thuật toán 2.7 trừu tượng và Thuật toán 2.2 cài đặt cụ thể) trong khung lý thuyết, phát biểu tổng quát cho bất kỳ tập nền Ω — không chỉ R — để dùng được cho cả trường hợp lấy mẫu theo tầng ($\Omega = R^s$) và theo cụm ($\Omega = C_i$) ở Mục 1 và 4.

1 Thuật toán 2.3 (sửa đổi) — Lấy mẫu tham lam đảm bảo tính dưới mô-đun

Ý tưởng

Khác với bản gốc — chọn ngẫu nhiên một luật hạt giống R_{tg} rồi lọc hàng loạt các luật không tương đồng trong lân cận của nó — phiên bản sửa bỏ hoàn toàn yếu tố ngẫu nhiên trong bước chọn luật, thay bằng nguyên tắc tham lam tất định: tại mỗi bước, luật được chọn để đưa vào $\tilde{R}$ là luật mang lại lợi ích biên lớn nhất đối với Rep, tính trên toàn bộ các luật còn lại chưa được chọn. Mỗi vòng lặp chỉ thêm đúng **một** luật duy nhất — không còn khái niệm “tập lân cận” $N(R_{tg})$ hay “lọc hàng loạt” $T(R_{tg})$ như bản gốc.

Các bước thực hiện

Bước 1. Khởi tạo: Đặt $\tilde{R} = \emptyset$; khởi tạo bảng $\text{Cov}(r) = 0$ với mọi $r \in R$; xác định $n = |R|$ và ngân sách $m = \lceil \theta \cdot n \rceil$.

Bước 2. Vòng lặp chọn tham lam (m vòng, hoặc đến khi đạt ngưỡng δ): Tại mỗi vòng lặp:

- (a) Với mỗi luật ứng viên $r \in R \setminus \tilde{R}$, tính lợi ích biên $\Delta(r)$ dựa trên bảng Cov hiện có (Bổ đề 1).
- (b) Chọn $r^* = \arg \max_{r \in R \setminus \tilde{R}} \Delta(r)$ — luật có lợi ích biên lớn nhất.
- (c) Thêm r^* vào $\tilde{R}$; cập nhật lại bảng $\text{Cov}(r')$ với mọi $r' \in R$.
- (d) (Tuỳ chọn) Kiểm tra điều kiện dừng sớm: nếu độ phủ trung bình $\frac{1}{n} \sum_{r'} \text{Cov}(r') \geq \delta$, dừng vòng lặp dù chưa đủ m luật.

Bước 3. Xây dựng FKGS: Từ tập luật thu gọn $\tilde{R}$, suy ra $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$ theo đúng cấu trúc FKGS gốc (Định nghĩa 1.4), thu được $FKGS = (\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}, \tilde{R})$.

Thuật toán

Độ phức tạp

Vòng lặp while chạy tối đa m bước; mỗi bước duyệt $O(n)$ ứng viên, mỗi ứng viên tốn $O(n)$ để tính $\Delta(r)$ (cách cài trực tiếp), cho tổng chi phí mỗi bước $O(n^2)$ hoặc $O(n)$ nếu duy trì Cov tăng dần đúng kỹ thuật của GreedyFKGS. Tổng độ phức tạp:

$$T(n) = O(m \cdot n) = O(\theta \cdot n^2),$$

thấp hơn bản gốc $O(n^2(1 + k\theta))$ vì không còn hệ số k (do bỏ bước tìm tập lân cận $N(R_{tg})$).

Lý lẽ bảo chứng Submodular

Định lý 1 (Bảo chứng của Thuật toán 2.3 sửa đổi). Gọi $\tilde{R}_0 = \emptyset, \tilde{R}_1, \dots, \tilde{R}_m$ là dãy tập hợp sinh bởi Thuật toán 1 với ngân sách $m = \lceil \theta n \rceil$ (bỏ qua điều kiện dừng sớm tuỳ chọn ở Bước 3, tức chạy đủ m bước). Khi đó

$$\text{Rep}(\tilde{R}_m) \geq \left(1 - \frac{1}{e}\right) \cdot \text{OPT}, \quad \text{OPT} := \max_{S \subseteq R, |S| \leq m} \text{Rep}(S).$$

Algorithm 1 Lấy mẫu tham lam đảm bảo tính dưới mô-đun – FKGS (sửa đổi)

Require: $FKG = (R, V, L, A, B)$, θ : tỉ lệ lấy mẫu, δ : ngưỡng dừng sớm (tùy chọn)

Ensure: $FKGS = (\tilde{R}, \tilde{V}, \tilde{L}, \tilde{A}, \tilde{B})$

```
1:  $\tilde{R} \leftarrow \emptyset$  ▷ Khởi tạo tập  $\tilde{R}$ 
2:  $\text{Cov}(r) \leftarrow 0$  với mọi  $r \in R$  ▷ Khởi tạo bảng độ phủ
3:  $n \leftarrow |R|$ ;  $m \leftarrow \lceil \theta \cdot n \rceil$  ▷ Xác định kích thước  $R$  và ngân sách lấy mẫu
4: while  $|\tilde{R}| < m$  do
5:   for each  $r \in R \setminus \tilde{R}$  do
6:      $\Delta(r) \leftarrow \frac{1}{n} \sum_{r' \in R} [\max(\text{Cov}(r'), \text{Sim}(r', r)) - \text{Cov}(r')]$  ▷ Lợi ích biên của  $r$  đối
    với Rep
7:   end for
8:    $r^* \leftarrow \arg \max_{r \in R \setminus \tilde{R}} \Delta(r)$  ▷ Chọn luật lợi ích biên lớn nhất – KHÔNG chọn ngẫu
    nhiên
9:    $\tilde{R} \leftarrow \tilde{R} \cup \{r^*\}$  ▷ Thêm luật  $r^*$  vào tập mẫu
10:   $\text{Cov}(r') \leftarrow \max(\text{Cov}(r'), \text{Sim}(r', r^*))$  với mọi  $r' \in R$  ▷ Cập nhật độ phủ toàn cục
11:  if  $\frac{1}{n} \sum_{r' \in R} \text{Cov}(r') \geq \delta$  then
12:    break ▷ Dừng sớm nếu đã đạt ngưỡng phủ  $\delta$ 
13:  end if
14: end while
15: Xây dựng  $FKGS = (\tilde{R}, \tilde{V}, \tilde{L}, \tilde{A}, \tilde{B})$  ▷ Suy ra  $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$  theo cấu trúc FKG gốc
16: return  $FKGS$ 
```

Proof. Bước 1 — đối chiếu từng dòng lệnh với điều kiện (i)–(ii) nêu ở đầu chương. Thuật toán 1 khởi tạo $\text{Cov}(r) = 0$ với mọi $r \in R$ (dòng 3) và cập nhật $\text{Cov}(r') \leftarrow \max(\text{Cov}(r'), \text{Sim}(r', r^*))$ với mọi $r' \in R$ ngay sau khi thêm r^* (dòng “ $\text{Cov}(r') \leftarrow \max(\text{Cov}(r'), \text{Sim}(r', r^*))$ ” đây đúng là quy tắc duy trì Cov nêu trong Bổ đề 1 với $\Omega = R$. Do đó, theo Bổ đề 1,

$$\Delta(r) = \frac{1}{n} \sum_{r' \in R} [\max(\text{Cov}(r'), \text{Sim}(r', r)) - \text{Cov}(r')] = \text{Rep}(\tilde{R} \cup \{r\}) - \text{Rep}(\tilde{R})$$

tại mọi bước, với $\tilde{R}$ là tập đang có ngay trước bước đó. Dòng “ $r^* \leftarrow \arg \max_{r \in R \setminus \tilde{R}} \Delta(r)$ ” chọn đúng $\arg \max$ lợi ích biên **trên toàn bộ** $R \setminus \tilde{R}$ — không giới hạn bởi vị trí, kết nối đồ thị hay quy tắc ngẫu nhiên nào, nên thỏa điều kiện (i). Dòng “ $\tilde{R} \leftarrow \tilde{R} \cup \{r^*\}$ ” chỉ thêm đúng một phần tử mỗi lượt lặp **while**, thỏa điều kiện (ii).

Bước 2 — áp dụng Bổ đề 2 (khung lý thuyết). Vì tại mọi bước $t = 1, \dots, m$, việc chọn $r_t^* = \arg \max_{r \notin \tilde{R}_{t-1}} [\text{Rep}(\tilde{R}_{t-1} \cup \{r\}) - \text{Rep}(\tilde{R}_{t-1})]$ và cập nhật $\tilde{R}_t = \tilde{R}_{t-1} \cup \{r_t^*\}$ trùng khớp đúng quy tắc chọn của Thuật toán 2.7 (khung tham lam tổng quát) trong khung lý thuyết, Bổ đề 2 (tính tương đương giữa Thuật toán 2.7 và Thuật toán 2.2, áp dụng verbatim vì cơ chế bảng Cov giống hệt nhau) khẳng định dãy $(\tilde{R}_t)_{t=0}^m$ trùng từng phần tử với dãy sinh bởi Thuật toán 2.7 chạy trên cùng (R, m) với cùng quy tắc phá hòa.

Bước 3 — áp dụng Định lý 5. Vì Rep đơn điệu và dưới mô-đun trên 2^R (Định lý 4), và dãy $(\tilde{R}_t)$ ở Bước 2 chính là một lượt chạy hợp lệ của thuật toán tham lam tổng quát, Định lý 5 (Nemhauser) áp dụng trực tiếp cho dãy này, cho

$$\text{Rep}(\tilde{R}_m) \geq \left(1 - \frac{1}{e}\right) \text{OPT}. \quad \square$$

Nhận xét 2 (Ví dụ số minh hoạ). Xét lại ví dụ 14 luật đã trình bày ở phần minh hoạ gốc của Thuật toán 2.3 (Bảng 2.1 trong tài liệu thuật toán lấy mẫu FKG: 14 luật với 4 thuộc tính Outlook, Temperature, Humidity, Windy), dùng $\text{Sim}(R_i, R_j) = 1 - d(R_i, R_j)$ với d là khoảng cách Hamming chuẩn hoá trên 4 thuộc tính (không điều kiện cùng nhãn, để đơn giản hoá phép tính tay), và $\theta = 30\% \Rightarrow$ ngưỡng dừng $\theta n = 4.2$ (dừng khi $|\tilde{R}| \geq 5$).

Bước $t = 1$ ($\text{Cov} \equiv 0$): theo Bổ đề 1, $\Delta(r) = \text{Rep}(\{r\}) = \frac{1}{14} \sum_{r'} \text{Sim}(r', r)$ — tức trung bình cộng similarity của r với 13 luật còn lại (cộng 1 cho chính nó). Đếm tần suất mỗi giá trị thuộc tính trong 14 luật (Outlook: Sunny/Overcast/Rainy = 5/4/5; Temperature: Hot/Mild/Cool = 4/6/4; Humidity: High/Normal = 7/7; Windy: FALSE/TRUE = 7/7) và tính tổng số luật trùng từng thuộc tính (trừ chính nó), ta được $\Delta(R_4) = \Delta(R_8) = \Delta(R_{10}) = \Delta(R_{11}) = \Delta(R_{14}) = 0.4464$ — giá trị lớn nhất, đồng hạng ở năm luật. Chọn R_4 theo thứ tự liệt kê $\Rightarrow \tilde{R}_1 = \{R_4\}$.

Các bước $t = 2, 3, 4$: lặp lại đúng cơ chế trên (tính Δ cho các ứng viên còn lại dựa vào Cov đã cập nhật, chọn $\arg \max$), thu được đúng dãy đã tính trong ví dụ minh hoạ của Thuật toán 2.2 (GreedyFKGS) ở Chương 2 — vì cơ chế hai thuật toán nay trùng khớp hoàn toàn theo Bổ đề 1:

$$t=2: R_6 (\Delta=0.1964); \quad t=3: R_1 (\Delta=0.0893); \quad t=4: R_5 (\Delta=0.0357).$$

Tại $t = 4$: $\tilde{R}_4 = \{R_4, R_6, R_1, R_5\}$, và tính trực tiếp $\text{Rep}(\tilde{R}_4) = \frac{1}{14} \sum_{r'} \text{Cov}(r') = \frac{10.75}{14} \approx 0.7679$.

Bước $t = 5$: theo Mệnh đề 12 (khung lý thuyết), dãy lợi ích biên (Δ_t) đơn điệu giảm, nên $\Delta_5 \leq \Delta_4 = 0.0357$. Do đó, không cần tính chi tiết ứng viên thứ năm, ta có ngay cận

$$0.7679 = \text{Rep}(\tilde{R}_4) \leq \text{Rep}(\tilde{R}_5) \leq \text{Rep}(\tilde{R}_4) + \Delta_4 \approx 0.8036.$$

Đây là minh hoạ cụ thể cho thấy $\text{Rep}(\tilde{R})$ tăng đơn điệu và có thể chặn được từng bước bằng các đại lượng đã tính, không cần thực hiện lại toàn bộ phép tính $\arg \max$ trên 10 ứng viên còn lại — một hệ quả thực dụng trực tiếp của tính chất đã chứng minh ở Chương 2.

Ý tưởng

Bước 1 (phân tầng) và Bước 2 (phân bổ cỡ mẫu mỗi tầng) của bản gốc được **giữ nguyên**, vì đây là các phép tính tất định không liên quan đến submodularity. Lỗi cấu trúc chỉ nằm ở Bước 3: việc chọn R_{tg} ngẫu nhiên trong mỗi tầng. Phiên bản sửa thay Bước 3 bằng vòng lặp **tham lam đúng** m_s **bước** trong mỗi tầng: tại mỗi bước, tính lợi ích biên $\Delta_s(r)$ của mọi ứng viên còn lại trong tầng đối với hàm đại diện cục bộ Rep_s , và chọn $r^* = \arg \max_r \Delta_s(r)$. Nhờ vậy mỗi tầng tự thân là một lượt chạy GreedyFKGS thu nhỏ.

Các bước thực hiện

Bước 1. Phân tầng (không đổi): Chia tập bản ghi R thành S tầng $R^1, R^2, \dots, R^S$ theo tiêu chí strat_by.

Bước 2. Phân bổ cỡ mẫu mỗi tầng (không đổi): Với mỗi tầng s , tính cỡ mẫu m_s theo phương pháp proportional/neyman/equal, sau đó giới hạn $m_s \leq |R^s|$.

Bước 3. Lấy mẫu tham lam trong từng tầng (sửa đổi): Với mỗi tầng s , khởi tạo $\tilde{R}^s = \emptyset$ và bảng $\text{Cov}_s \equiv 0$ trên R^s ; lặp đúng m_s bước, mỗi bước tính lợi ích biên $\Delta_s(r)$ cho mọi $r \in R^s \setminus \tilde{R}^s$, chọn $r^* = \arg \max_r \Delta_s(r)$, thêm vào $\tilde{R}^s$ và cập

nhật Cov_s . Bước này có thể song song hoá giữa các tầng vì chúng độc lập với nhau.

Bước 4. Gộp kết quả (không đổi): Hợp tất cả các mẫu tầng $\tilde{R}^s$ lại thành tập mẫu toàn cục $\tilde{R} = \bigcup_s \tilde{R}^s$, từ đó suy ra $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$ theo cấu trúc FKG gốc.

Thuật toán

Algorithm 2 Lấy mẫu phân tầng đảm bảo tính dưới mô-đun – SFKGS (sửa đổi)

Require: $FKG(V, L, A, B, R)$, θ (tỉ lệ mẫu tổng), S (số tầng), phương pháp phân tầng strat_by , phương pháp phân bổ $\text{alloc_method} \in \{\text{proportional}, \text{neyman}, \text{equal}\}$

Ensure: $FKGS = (\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}, \tilde{R})$

```

1:  $\{R^1, R^2, \dots, R^S\} \leftarrow \text{Partition}(R, \text{strat\_by}, S)$       ▷ Phân tầng  $R$  theo tiêu chí  $\text{strat\_by}$  (không đổi)
2:  $\tilde{R} \leftarrow \emptyset$                                               ▷ Khởi tạo tập mẫu toàn cục
3: for  $s = 1 \rightarrow S$  do
4:   if  $\text{alloc\_method} = \text{"proportional"}$  then
5:      $m_s \leftarrow \lceil \theta \cdot |R^s| \rceil$ 
6:   else if  $\text{alloc\_method} = \text{"neyman"}$  then
7:      $\sigma_s \leftarrow \text{EstimateVariance}(R^s)$ 
8:      $m_s \leftarrow \left\lceil \frac{\theta \cdot |R| \cdot |R^s| \cdot \sigma_s}{\sum_{j=1}^S (|R^j| \cdot \sigma_j)} \right\rceil$ 
9:   else if  $\text{alloc\_method} = \text{"equal"}$  then
10:     $m_s \leftarrow \lceil \theta \cdot |R| / S \rceil$ 
11:   end if
12:    $m_s \leftarrow \min(m_s, |R^s|)$ 
13: end for                                                    ▷ Phân bổ cỡ mẫu mỗi tầng theo  $\text{alloc\_method}$  (không đổi)
14: for  $s = 1 \rightarrow S$  do
15:    $\tilde{R}^s \leftarrow \emptyset$ 
16:    $\text{Cov}_s(r) \leftarrow 0$  với mọi  $r \in R^s$ 
17:   while  $|\tilde{R}^s| < m_s$  do
18:     for each  $r \in R^s \setminus \tilde{R}^s$  do
19:        $\Delta_s(r) \leftarrow \frac{1}{|\tilde{R}^s|} \sum_{r' \in \tilde{R}^s} [\max(\text{Cov}_s(r'), \text{Sim}(r', r)) - \text{Cov}_s(r')]$  ▷ Lợi ích biên của  $r$  trong tầng  $s$ 
20:     end for
21:      $r^* \leftarrow \arg \max_{r \in R^s \setminus \tilde{R}^s} \Delta_s(r)$  ▷ Chọn luật lợi ích biên lớn nhất trong tầng – KHÔNG chọn ngẫu nhiên
22:      $\tilde{R}^s \leftarrow \tilde{R}^s \cup \{r^*\}$                                 ▷ Thêm  $r^*$  vào mẫu của tầng  $s$ 
23:      $\text{Cov}_s(r') \leftarrow \max(\text{Cov}_s(r'), \text{Sim}(r', r^*))$  với mọi  $r' \in R^s$  ▷ Cập nhật độ phủ trong tầng  $s$ 
24:   end while
25:    $\tilde{R} \leftarrow \tilde{R} \cup \tilde{R}^s$                                     ▷ Gộp mẫu tầng  $s$  vào mẫu toàn cục
26: end for                                                    ▷ Lấy mẫu tham lam trong từng tầng (sửa đổi)
27: return  $\tilde{R}$  (và  $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$  suy ra từ  $\tilde{R}$  theo cấu trúc FKG gốc)

```

Độ phức tạp

Với mỗi tầng s kích thước $n_s = |R^s|$, chi phí lấy mẫu tham lam là $O(m_s \cdot n_s)$. Tổng trên S tầng, trong trường hợp cân bằng ($n_s \approx n/S$):

$$T_{\text{SFKGS}} = \sum_{s=1}^S O(m_s \cdot n_s) = O(\theta n^2 / S),$$

nhỏ hơn Greedy toàn cục $O(\theta n^2)$ một hệ số S nhờ chia nhỏ bài toán, đồng thời có bảo chứng đầy đủ.

Lý lẽ bảo chứng Submodular

Định nghĩa 1 (OPT phân bổ theo tầng). Với ngân sách $(m_1, \dots, m_S)$ đã ấn định ở Bước 2 (theo *alloc_method*), đặt

$$\text{Rep}_s^* := \max_{S_s \subseteq R^s, |S_s| \leq m_s} \text{Rep}_s(S_s), \quad p_s := \frac{|R^s|}{|R|},$$

và định nghĩa giá trị tối ưu phân bổ theo tầng

$$\text{OPT}_{\text{phân bổ}} := \sum_{s=1}^S p_s \text{Rep}_s^*.$$

Đại lượng này **khác** với $\text{OPT} = \max_{S \subseteq R, |S| \leq m} \text{Rep}(S)$ của bài toán gốc (P), vì OPT cho phép phân bổ ngân sách $m = \sum_s m_s$ tùy ý giữa các tầng, còn $\text{OPT}_{\text{phân bổ}}$ bị ràng buộc đúng m_s phần tử cho mỗi tầng s như đã ấn định trước ở Bước 2.

Mệnh đề 1 (So sánh hai chuẩn tối ưu). $\text{OPT}_{\text{phân bổ}} \leq \text{OPT}$, với đẳng thức xảy ra khi và chỉ khi nghiệm tối ưu toàn cục S^* của (P) (với $m = \sum_s m_s$) tình cờ thỏa $|S^* \cap R^s| = m_s$ với mọi s .

Proof. Gọi $S_s^* \subseteq R^s$, $|S_s^*| \leq m_s$ là nghiệm đạt Rep_s^* tại mỗi tầng, và đặt $\hat{S} := \bigcup_s S_s^*$. Vì các tầng rời nhau, $|\hat{S}| = \sum_s |S_s^*| \leq \sum_s m_s = m$, nên $\hat{S}$ là một tập **khả thi** (không nhất thiết tối ưu) của bài toán (P) với ngân sách m . Dưới giả thiết phân tách (Định nghĩa 2 bên dưới), $\text{Rep}(\hat{S}) = \sum_s p_s \text{Rep}_s(S_s^*) = \sum_s p_s \text{Rep}_s^* = \text{OPT}_{\text{phân bổ}}$. Vì $\text{OPT} = \max_{S \subseteq R, |S| \leq m} \text{Rep}(S) \geq \text{Rep}(\hat{S})$ (do $\hat{S}$ chỉ là một ứng viên khả thi trong tập mà OPT lấy max), suy ra $\text{OPT}_{\text{phân bổ}} \leq \text{OPT}$. Đẳng thức xảy ra khi và chỉ khi $\hat{S}$ (hay một tập khả thi khác đạt cùng giá trị) chính là nghiệm tối ưu toàn cục S^* , tức S^* phân bổ đúng m_s phần tử cho mỗi tầng. $\square$

Định nghĩa 2 (Giả thiết phân tách (H)). Với mọi $r \in R^s$ và mọi $S \subseteq R$,

$$\max_{s' \in S} \text{Sim}(r, s') = \max_{s' \in S \cap R^s} \text{Sim}(r, s'). \quad (\text{H})$$

Nói cách khác, đại diện tốt nhất cho luật r (thuộc tầng R^s) luôn nằm trong chính tầng R^s , không có đại diện chéo tầng nào tốt hơn.

Nhận xét 3 (Hệ quả khi (H) bị vi phạm — dẫn Nhận xét 20). Nếu (H) không đúng, với $S = \bigcup_s S_s$ bất kỳ (mỗi $S_s \subseteq R^s$), vì việc cho phép đại diện chéo tầng chỉ có thể **làm tăng** giá trị $\max_{s' \in S} \text{Sim}(r, s')$ so với $\max_{s' \in S \cap R^s} \text{Sim}(r, s')$ (thêm ứng viên vào tập lấy max không giảm giá trị max), Nhận xét 20 (khung lý thuyết) chỉ ra

$$\text{Rep}(S) \geq \sum_s p_s \text{Rep}_s(S_s)$$

(bất đẳng thức thay vì đẳng thức). Do toàn bộ Định lý 2 dưới đây chỉ dùng chiều $\text{Rep}(\tilde{R}) \geq \sum_s p_s \text{Rep}_s(\tilde{R}^s)$ để suy ra cận dưới, bảo chứng **vẫn đúng vững, thậm chí với biên an toàn hơn**, khi (H) bị vi phạm một phần.

Định lý 2 (Bảo chứng của Thuật toán 2.5 sửa đổi). Với giả thiết (H) (hoặc, theo Nhận xét 3, ngay cả khi không có (H)),

$$\text{Rep}(\tilde{R}) \geq \left(1 - \frac{1}{e}\right) \cdot \text{OPT}_{\text{phân bổ}}.$$

Proof. Bước 1 — bảo chứng cục bộ trong từng tầng. Cố định tầng s . Vòng lặp `while` trong Bước 3 của thuật toán sửa đổi duy trì bảng Cov_s trên $\Omega = R^s$ đúng theo quy tắc của Bổ đề 1 (khởi tạo $\text{Cov}_s \equiv 0$, cập nhật $\text{Cov}_s(r') \leftarrow \max(\text{Cov}_s(r'), \text{Sim}(r', r^*))$ với mọi $r' \in R^s$ sau mỗi lần thêm r^*), và chọn $r^* = \arg \max_{r \in R^s \setminus \widetilde{R}^s} \Delta_s(r)$ — đúng $\arg \max$ lợi ích biên toàn cục **trong phạm vi** R^s , thêm đúng một phần tử mỗi bước. Áp dụng đúng lập luận của Định lý 1 (Bước 1-3), thay $R, \text{Rep}, \text{Cov}, m$ bằng $R^s, \text{Rep}_s, \text{Cov}_s, m_s$, ta được: dãy $(\widetilde{R}_t^s)_{t=0}^{m_s}$ trùng với dãy sinh bởi thuật toán tham lam tổng quát chạy trên (R^s, m_s) , và theo Định lý 5,

$$\text{Rep}_s(\widetilde{R}^s) \geq \left(1 - \frac{1}{e}\right) \text{Rep}_s^*, \quad \forall s = 1, \dots, S. \quad (*)$$

Bước 2 — gộp qua các tầng bằng Định lý 7. Vì $\{R^1, \dots, R^S\}$ là một phân hoạch rời nhau, phủ kín R (Bước 1 của thuật toán), theo giả thiết (H) (hoặc theo bất đẳng thức của Nhận xét 3 nếu (H) không đúng):

$$\text{Rep}(\widetilde{R}) \geq \sum_{s=1}^S p_s \text{Rep}_s(\widetilde{R}^s).$$

Kết hợp với (*) và nhân từng số hạng với $p_s \geq 0$ rồi cộng qua s (bảo toàn chiều bất đẳng thức):

$$\text{Rep}(\widetilde{R}) \geq \sum_{s=1}^S p_s \text{Rep}_s(\widetilde{R}^s) \geq \left(1 - \frac{1}{e}\right) \sum_{s=1}^S p_s \text{Rep}_s^* = \left(1 - \frac{1}{e}\right) \text{OPT}_{\text{phân bổ}}. \quad \square$$

Nhận xét 4. Theo Mệnh đề 1, cận trên đây **yếu hơn** cận $(1 - 1/e) \cdot \text{OPT}$ mà Thuật toán 2.3/2.6/2.8 (không phân hoạch) đạt được, vì $\text{OPT}_{\text{phân bổ}} \leq \text{OPT}$ nói chung là bất đẳng thức ngặt. Đây là **cái giá lý thuyết** phải trả để đổi lấy lợi ích tính toán $O(\theta n^2/S)$ thay vì $O(\theta n^2)$ (xem mục Độ phức tạp) — một đánh đổi cần nêu rõ khi trình bày kết quả trong luận án, thay vì ngấm hiểu Thuật toán 2.5 đạt cùng mức bảo chứng với GreedyFKGS.

2 Thuật toán 2.6 — Sửa lỗi điều kiện dừng (giữ nguyên đặc trưng lấy mẫu hệ thống)

Ý tưởng

Bản gốc mắc lỗi ở Bước 4 (vòng bù): đặc tả dừng cụm “lặp lại Bước 3 ... cho đến khi đủ target hoặc đã thử hết n vị trí” — ngữ nghĩa của một vòng lặp thật sự — nhưng mã giả chỉ viết dưới dạng một khối `if` chạy đúng một lần, không có tập hợp nào ghi lại các điểm bắt đầu đã thử. Ngoài ra, khi $\theta \geq 0.5$ thì bước nhảy $w = \lfloor n/\text{target} \rfloor = 1$, khiến điều kiện “chọn điểm bắt đầu thứ hai $r' \neq r$ ” không còn điểm nào khác để chọn. Phiên bản sửa **giữ nguyên hoàn toàn** cơ chế lấy mẫu theo vị trí, bước nhảy w và cửa sổ cục bộ $2k$ của bản gốc, chỉ thay cách hình thức hoá Bước 3-4: gộp thành một vòng lặp `while` duy nhất với điều kiện dừng kép $|\tilde{R}| < \text{target}$ và $\text{Candidates} \neq \emptyset$ — đúng mẫu hình đã dùng ở Thuật toán 2.7 cho vòng lặp trong từng cụm — trong đó Candidates là tập các điểm bắt đầu $r \in [1, w]$ còn chưa thử, bị loại dần đúng 1 phần tử mỗi vòng lặp.

Các bước thực hiện

Bước 1. Sắp thứ tự (không đổi): Sắp toàn bộ R theo `order_by` để thu được dãy $\pi(R)$; xác định $n = |R|$ và cỡ mẫu mục tiêu $\text{target} = \lceil \theta \cdot n \rceil$.

Bước 2. Tính khoảng cách lấy mẫu (sửa đổi): Tính bước nhảy hệ thống $w = \max(1, \lfloor n/\text{target} \rfloor)$ — chặn dưới bằng 1 để loại trường hợp biên gây treo khi $\theta \geq 0.5$; khởi tạo tập ứng viên điểm bắt đầu $\text{Candidates} = \{1, 2, \dots, w\}$.

Bước 3+4. Lấy mẫu hệ thống có vòng bù tích hợp (gộp và sửa đổi): Lặp `while` với điều kiện $|\tilde{R}| < \text{target}$ và $\text{Candidates} \neq \emptyset$: chọn ngẫu nhiên một điểm bắt đầu $r \in \text{Candidates}$, loại r khỏi Candidates ngay lập tức, rồi duyệt tuần hoàn target vị trí cách nhau w bắt đầu từ r ; tại mỗi vị trí, kiểm tra $d(R_p, R_{tg}) > \varepsilon$ với mọi R_p trong cửa sổ $2k$ lân cận theo thứ tự — nếu thỏa thì nhận bản ghi, ngược lại bỏ qua và tăng `extra_offset` để bù vào vị trí kế tiếp.

Thuật toán

Độ phức tạp

Vòng `while` bên ngoài chạy tối đa w lượt vì Candidates giảm chặt đúng 1 phần tử mỗi lượt; mỗi lượt tốn $O(\text{target})$ cho vòng `for` bên trong (đã có **break** sớm khi đủ mẫu). Tổng độ phức tạp bị chặn bởi $O(w \cdot \text{target})$, xấp xỉ $O(n)$ trong trường hợp cân bằng ($w \cdot \text{target} \approx n$) — **thuật toán luôn dừng** với cận trên tường minh, kể cả khi dữ liệu đồng nhất cao khiến không đạt đủ target (khi đó chỉ dừng sớm kèm cảnh báo, không treo).

Nhận xét 5. Thuật toán trên chỉ sửa lỗi *tính dừng*, không thay đổi cơ chế chọn theo vị trí/cửa sổ cục bộ của bản gốc — nên vẫn không thỏa điều kiện (i) đã nêu ở đầu chương (chọn theo $\arg \max$ lợi ích biên toàn cục đối với Rep). Phần tiếp theo trình bày phương án thay thế hoàn toàn bằng GreedyFKGS để đạt bảo chứng $(1 - 1/e) \cdot \text{OPT}$, đánh đổi lấy việc mất hoàn toàn đặc trưng “hệ thống” của thiết kế gốc.

Algorithm 3 Lấy mẫu có hệ thống – SysFKGS (đã sửa lỗi điều kiện dừng)

Require: $FKG(V, L, A, B, R)$, θ (tỉ lệ mẫu), ε (ngưỡng tương đồng), $\text{order_by} \in \{\text{natural}, \text{sort_key}, \text{embedding_sfc}\}$, k (kích thước cửa sổ kiểm tra cục bộ, mặc định $k = 5$)

Ensure: $FKGS = (\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}, \tilde{R})$

```
1:  $\pi(R) \leftarrow \text{OrderSequence}(R, \text{order\_by})$   $\triangleright$  Sắp toàn bộ  $R$  theo  $\text{order\_by}$ 
2:  $n \leftarrow |R|$ ;  $\text{target} \leftarrow \lceil \theta \cdot n \rceil$ 
3:  $w \leftarrow \max(1, \lfloor n/\text{target} \rfloor)$   $\triangleright$  Bước nhảy hệ thống – đảm bảo  $w \geq 1$ 
4:  $\tilde{R} \leftarrow \emptyset$ ;  $\text{Candidates} \leftarrow \{1, 2, \dots, w\}$   $\triangleright$  Tập điểm bắt đầu khả dĩ, cùng mẫu hình với  $\text{Candidates}_i$  ở Thuật toán 2.7
5: while  $|\tilde{R}| < \text{target}$  and  $\text{Candidates} \neq \emptyset$  do
6:   Chọn ngẫu nhiên  $r \in \text{Candidates}$ 
7:    $\text{Candidates} \leftarrow \text{Candidates} \setminus \{r\}$   $\triangleright$  Loại ngay – đảm bảo tiến triển, không thử lại
8:    $\text{extra\_offset} \leftarrow 0$ 
9:   for  $j = 0 \rightarrow \text{target} - 1$  do
10:    if  $|\tilde{R}| \geq \text{target}$  then
11:      break  $\triangleright$  Đã đủ mẫu, dừng sớm
12:    end if
13:     $\text{idx} \leftarrow ((r + j \cdot w + \text{extra\_offset} - 1) \bmod n) + 1$   $\triangleright$  Circular, tránh vượt biên
14:     $R_{tg} \leftarrow \pi(R)[\text{idx}]$ 
15:     $K(R_{tg}) \leftarrow \{\pi(R)[((\text{idx} - 1 - t) \bmod n) + 1] : t = 1..k\} \cup \{\pi(R)[((\text{idx} - 1 + t) \bmod n) + 1] : t = 1..k\}$   $\triangleright$  Cửa sổ  $2k$  phần tử lân cận trong thứ tự (circular)
16:    if  $\forall R_p \in K(R_{tg}) : d(R_p, R_{tg}) > \varepsilon$  then
17:       $\tilde{R} \leftarrow \tilde{R} \cup \{R_{tg}\}$   $\triangleright$  Không tương đồng cục bộ – nhận bản ghi
18:    else
19:       $\text{extra\_offset} \leftarrow \text{extra\_offset} + 1$   $\triangleright$  Tương đồng cục bộ – bỏ qua, bù vị trí kế tiếp
20:    end if
21:  end for
22: end while
23: if  $|\tilde{R}| < \text{target}$  then
24:   Cảnh báo: “Không đạt đủ target sau khi đã thử hết  $w$  điểm bắt đầu khả dĩ – dữ liệu có cấu trúc cục bộ đồng nhất cao”
25: end if
26: return  $\tilde{R}$  (và  $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$  suy ra từ  $\tilde{R}$  theo cấu trúc FKG gốc)
```

3 Thuật toán 2.6 (sửa đổi) — Lấy mẫu tham lam thay thế lấy mẫu hệ thống

Ý tưởng

Bản gốc chọn luật theo **vị trí cố định** trong thứ tự $\pi(R)$ (bước nhảy hệ thống w) và chỉ kiểm tra trùng lặp trong một **cửa sổ cục bộ** $2k$ phần tử lân cận theo thứ tự — hai cơ chế này hoàn toàn không tham chiếu đến giá trị Rep. Phiên bản sửa bỏ hoàn toàn cơ chế duyệt theo vị trí (thứ tự $\pi(R)$, bước nhảy w , cửa sổ $K(R_{tg})$), thay bằng vòng lặp tham lam tất định — chọn đúng một luật có lợi ích biên toàn cục lớn nhất mỗi bước, kiểm tra trùng lặp qua bảng Cov toàn cục.

Nhận xét 6. Cần lưu ý: nguyên lý “lấy mẫu có hệ thống” (định vị theo vị trí) và

nguyên lý “tham lam theo lợi ích biên” (định vị theo giá trị hàm mục tiêu) là **hai tiêu chí sắp xếp ưu tiên xung khắc nhau**. Sau khi sửa, thuật toán **không còn giữ bất kỳ đặc trưng “hệ thống” nào** và trùng với GreedyFKGS.

Các bước thực hiện

Bước 1. Khởi tạo: Đặt $\tilde{R} = \emptyset$; khởi tạo bảng $\text{Cov}(r) = 0$ với mọi $r \in R$; xác định $n = |R|$ và ngân sách $\text{target} = \lceil \theta \cdot n \rceil$. (Bỏ hoàn toàn bước sắp thứ tự $\pi(R)$ và tính khoảng cách hệ thống w của bản gốc.)

Bước 2. Vòng lặp chọn tham lam (target vòng): Tại mỗi vòng lặp, tính lợi ích biên $\Delta(r)$ cho mọi ứng viên còn lại $r \in R \setminus \tilde{R}$ (không giới hạn theo vị trí trong $\pi(R)$), chọn $r^* = \arg \max_r \Delta(r)$, thêm vào $\tilde{R}$, cập nhật bảng Cov **toàn cục** (không chỉ trong cửa sổ $2k$ lân cận như bản gốc).

Bước 3. Xây dựng FKGS: Suy ra $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$ từ $\tilde{R}$ theo cấu trúc FKG gốc. (Bỏ hoàn toàn Bước 5 gốc — vòng bù top-up — vì không còn khái niệm “thiếu chỉ tiêu do trùng lặp cục bộ” khi kiểm tra đã là toàn cục.)

Thuật toán

Algorithm 4 Lấy mẫu tham lam đảm bảo tính dưới mô-đun – thay thế SysFKGS (sửa đổi)

Require: $FKG(V, L, A, B, R)$, θ (tỉ lệ mẫu)

Ensure: $FKGS = (\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}, \tilde{R})$

```

1:  $\tilde{R} \leftarrow \emptyset$  ▷ Khởi tạo tập  $\tilde{R}$ 
2:  $\text{Cov}(r) \leftarrow 0$  với mọi  $r \in R$  ▷ Khởi tạo bảng độ phủ
3:  $n \leftarrow |R|$ ;  $\text{target} \leftarrow \lceil \theta \cdot n \rceil$  ▷ Bỏ bước sắp thứ tự  $\pi(R)$  và bước nhảy  $w$  của bản gốc
4: while  $|\tilde{R}| < \text{target}$  do
5:   for each  $r \in R \setminus \tilde{R}$  do
6:      $\Delta(r) \leftarrow \frac{1}{n} \sum_{r' \in R} [\max(\text{Cov}(r'), \text{Sim}(r', r)) - \text{Cov}(r')]$  ▷ Lợi ích biên toàn cục –
        KHÔNG dùng vị trí trong  $\pi(R)$ 
7:   end for
8:    $r^* \leftarrow \arg \max_{r \in R \setminus \tilde{R}} \Delta(r)$  ▷ Chọn theo giá trị Rep – KHÔNG chọn theo bước nhảy  $w$ 
9:    $\tilde{R} \leftarrow \tilde{R} \cup \{r^*\}$  ▷ Thêm luật  $r^*$  vào tập mẫu
10:   $\text{Cov}(r') \leftarrow \max(\text{Cov}(r'), \text{Sim}(r', r^*))$  với mọi  $r' \in R$  ▷ Cập nhật phủ TOÀN CỤC
    – KHÔNG chỉ của sổ  $2k$  lân cận
11: end while
12: return  $\tilde{R}$  (và  $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$  suy ra từ  $\tilde{R}$ ) ▷ Xây dựng FKGS theo cấu trúc FKG gốc

```

Độ phức tạp

$$T(n) = O(\text{target} \cdot n) = O(\theta \cdot n^2),$$

tăng đáng kể so với $O(n \log n + \theta nk)$ của bản gốc — đây là cái giá phải trả để đổi lấy bảo chứng lý thuyết, cần nêu rõ như một đánh đổi (trade-off) tương minh trong luận án.

Lý lẽ bảo chứng Submodular

Định lý 3 (Bảo chứng của Thuật toán 2.6 sửa đổi). Gọi $\tilde{R}_0 = \emptyset, \tilde{R}_1, \dots, \tilde{R}_{\text{target}}$ là dãy tập hợp sinh bởi Thuật toán 4 với $\text{target} = \lceil \theta n \rceil$. Khi đó $\text{Rep}(\tilde{R}_{\text{target}}) \geq (1 - 1/e) \cdot \text{OPT}$.

Proof. Đối chiếu dòng lệnh. Bảng Cov được khởi tạo $\equiv 0$ (dòng 3) và cập nhật $\text{Cov}(r') \leftarrow \max(\text{Cov}(r'), \text{Sim}(r', r^*))$ với mọi $r' \in R$ ngay sau khi thêm r^* — đúng quy tắc của Bổ đề 1 với $\Omega = R$, **không còn** phụ thuộc thứ tự $\pi(R)$, bước nhảy w , hay cửa sổ cục bộ $K(R_{tg})$ như bản gốc (các đại lượng này đã bị loại bỏ hoàn toàn khỏi thuật toán sửa đổi). Do đó $\Delta(r) = \text{Rep}(\tilde{R} \cup \{r\}) - \text{Rep}(\tilde{R})$ đúng theo Bổ đề 1, và dòng “ $r^* \leftarrow \arg \max_{r \in R \setminus \tilde{R}} \Delta(r)$ ” chọn đúng $\arg \max$ lợi ích biên trên toàn bộ $R \setminus \tilde{R}$, thêm đúng một phần tử mỗi bước — thỏa cả hai điều kiện (i)–(ii).

Áp dụng Bổ đề 2 và Định lý 5. Lập luận hoàn toàn giống Bước 2–3 của chứng minh Định lý 1 (chỉ khác tên biến target thay cho m , về bản chất là cùng một đại lượng $\lceil \theta n \rceil$): dãy $(\tilde{R}_t)$ trùng với dãy sinh bởi thuật toán tham lam tổng quát trên (R, target) theo Bổ đề 2, nên Định lý 5 áp dụng trực tiếp, cho $\text{Rep}(\tilde{R}_{\text{target}}) \geq (1 - 1/e) \cdot \text{OPT}$. $\square$

Nhận xét 7. Không tồn tại một “định lý gộp theo thứ tự/vị trí” nào trong khung lý thuyết hiện có (khác với trường hợp phân tầng/gom cụm, nơi Định lý 7 áp dụng được cho phân hoạch) để bảo toàn đặc trưng hệ thống của bản gốc mà vẫn giữ bảo chứng $(1 - 1/e)$ — lý do là tập $\pi(R)$ được sắp theo thứ tự không tạo thành một phân hoạch rời nhau của R theo nghĩa cần cho Định lý 7. Do đó không có phương án nào khác ngoài việc quy về GreedyFKGS (Định lý 3) nếu muốn có bảo chứng tất định dạng $(1 - 1/e) \cdot \text{OPT}$.

4 Thuật toán 2.7 (sửa đổi) — Lấy mẫu theo cụm đảm bảo tính dưới mô-đun

Ý tưởng

Bản gốc mắc ba lỗi cấu trúc: (1) chọn cụm nào được ghé thăm là ngẫu nhiên theo bảng alias, khiến một số cụm bị bỏ qua hoàn toàn; (2) chọn luật trong cụm đã chọn là ngẫu nhiên; (3) kiểm tra trùng lặp chỉ so với $\tilde{R}_i$ của riêng cụm đang xét, không so với $\tilde{R}$ toàn cục. Phiên bản sửa giữ nguyên Bước 1 (hình thành cụm), **bỏ hoàn toàn** cơ chế chọn cụm ngẫu nhiên (Bước 2-3 gốc), thay bằng việc **duyệt tuần tự qua tất cả M_c cụm** — không bỏ sót cụm nào — và trong mỗi cụm áp dụng vòng lặp tham lam đúng target_{*i*} bước dựa trên bảng Cov_{*i*} cục bộ trong cụm.

Các bước thực hiện

Bước 1. Hình thành cụm (không đổi): Áp dụng phương pháp gom cụm cluster_method để phân chia R thành M_c cụm $C_1, \dots, C_{M_c}$ (thực hiện một lần).

Bước 2. Lấy mẫu tham lam trong từng cụm (sửa đổi): Duyệt tuần tự $i = 1, \dots, M_c$ — **không bỏ sót cụm nào**. Với mỗi cụm C_i : xác định cỡ mẫu target_{*i*} (toàn bộ $|C_i|$ nếu one_stage, hoặc $\lceil \theta \cdot |C_i| \rceil$ nếu two_stage); khởi tạo $\tilde{R}_i = \emptyset$ và bảng Cov_{*i*} $\equiv 0$ trên C_i ; lặp đúng target_{*i*} bước, mỗi bước tính lợi ích biên $\Delta_i(r)$ cho mọi $r \in C_i \setminus \tilde{R}_i$, chọn $r^* = \arg \max_r \Delta_i(r)$, thêm vào $\tilde{R}_i$ và cập nhật Cov_{*i*}.

Bước 3. Gộp kết quả: Hợp $\tilde{R} = \bigcup_i \tilde{R}_i$; suy ra $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$ từ $\tilde{R}$ theo cấu trúc FKG gốc. (Bỏ hoàn toàn cơ chế tính xác suất chọn cụm và bảng alias của Bước 2-3 gốc.)

Thuật toán

Độ phức tạp

Với mỗi cụm C_i kích thước $n_i = |C_i|$, chi phí là $O(\text{target}_i \cdot n_i)$. Tổng trên M_c cụm, trường hợp cân bằng ($n_i \approx n/M_c$):

$$T_{\text{CFKGS}} = O(n) + O(\theta n^2/M_c),$$

rẻ hơn Greedy toàn cục một hệ số M_c , đồng thời có bảo chứng đầy đủ. So với bản gốc $O(n + \theta n(\log(n/M_c) + k))$, chi phí tăng do bỏ chỉ mục không gian k -NN, đổi lấy bảo chứng chất lượng.

Lý lẽ bảo chứng Submodular

Định nghĩa 3 (OPT phân bổ theo cụm). Tương tự Định nghĩa 1, với các cỡ mẫu (target₁, ..., target _{M_c}) đã ấn định ở Bước 2, đặt

$$\text{Rep}_i^* := \max_{S_i \subseteq C_i, |S_i| \leq \text{target}_i} \text{Rep}_i(S_i), \quad q_i := \frac{|C_i|}{|R|}, \quad \text{OPT}_{\text{phân bổ}}^{(\text{cụm})} := \sum_{i=1}^{M_c} q_i \text{Rep}_i^*.$$

Cũng như trường hợp phân tầng, $\text{OPT}_{\text{phân bổ}}^{(\text{cụm})} \leq \text{OPT}$ nói chung là bất đẳng thức ngặt (chứng minh y hệt Mệnh đề 1, thay R^s bằng C_i), vì nghiệm tối ưu toàn cục của (P) không bị ràng buộc phải phân bổ đúng target_{*i*} phần tử cho mỗi cụm.

Algorithm 5 Lấy mẫu theo gom cụm đảm bảo tính dưới mô-đun – CFKGS (sửa đổi)

Require: $FKG(V, L, A, B, R)$, θ (tỉ lệ mẫu tổng), M_c (số cụm), $\text{cluster_method} \in \{\text{connected_components}, \text{louvain}, \text{kmeans_embed}\}$, $\text{design} \in \{\text{one_stage}, \text{two_stage}\}$

Ensure: $FKGS = (\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}, \tilde{R})$

- 1: $\{C_1, C_2, \dots, C_{M_c}\} \leftarrow \text{FormClusters}(R, \text{cluster_method}, M_c)$ $\triangleright$ Hình thành cụm bằng cluster_method (không đổi)
- 2: $\tilde{R} \leftarrow \emptyset$ $\triangleright$ Khởi tạo tập mẫu toàn cục
- 3: **for** $i = 1 \rightarrow M_c$ **do**
- 4: **if** $\text{design} = \text{"one_stage"}$ **then**
- 5: $\text{target}_i \leftarrow |C_i|$
- 6: **else**
- 7: $\text{target}_i \leftarrow \lceil \theta \cdot |C_i| \rceil$
- 8: **end if**
- 9: $\tilde{R}_i \leftarrow \emptyset$
- 10: $\text{Cov}_i(r) \leftarrow 0$ với mọi $r \in C_i$
- 11: **while** $|\tilde{R}_i| < \text{target}_i$ **do**
- 12: **for each** $r \in C_i \setminus \tilde{R}_i$ **do**
- 13: $\Delta_i(r) \leftarrow \frac{1}{|C_i|} \sum_{r' \in C_i} [\max(\text{Cov}_i(r'), \text{Sim}(r', r)) - \text{Cov}_i(r')]$ $\triangleright$ Lợi ích biên của r trong cụm i
- 14: **end for**
- 15: $r^* \leftarrow \arg \max_{r \in C_i \setminus \tilde{R}_i} \Delta_i(r)$ $\triangleright$ Chọn theo lợi ích biên – KHÔNG chọn ngẫu nhiên
- 16: $\tilde{R}_i \leftarrow \tilde{R}_i \cup \{r^*\}$ $\triangleright$ Thêm r^* vào mẫu của cụm i
- 17: $\text{Cov}_i(r') \leftarrow \max(\text{Cov}_i(r'), \text{Sim}(r', r^*))$ với mọi $r' \in C_i$ $\triangleright$ Cập nhật độ phủ trong cụm i
- 18: **end while**
- 19: $\tilde{R} \leftarrow \tilde{R} \cup \tilde{R}_i$ $\triangleright$ Gộp mẫu cụm i vào mẫu toàn cục
- 20: **end for** $\triangleright$ Duyệt tuần tự HẾT mọi cụm – KHÔNG bỏ sót cụm nào
- 21: **return** $\tilde{R}$ (và $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$ suy ra từ $\tilde{R}$)

Định nghĩa 4 (Giả thiết phân tách theo cụm (H')). Với mọi $r \in C_i$ và mọi $S \subseteq R$: $\max_{s' \in S} \text{Sim}(r, s') = \max_{s' \in S \cap C_i} \text{Sim}(r, s')$ — đại diện tốt nhất cho r luôn nằm trong chính cụm C_i chứa nó.

Nhận xét 8 (Hệ quả khi (H') bị vi phạm). Hoàn toàn tương tự Nhận xét 3: nếu (H') không đúng, $\text{Rep}(S) \geq \sum_i q_i \text{Rep}_i(S_i)$ với $S = \bigcup_i S_i$ bất kỳ, nên bảo chứng dưới đây vẫn đúng, thậm chí với biên an toàn hơn.

Định lý 4 (Bảo chứng của Thuật toán 2.7 sửa đổi). Với giả thiết (H') (hoặc, theo nhận xét trên, ngay cả khi không có (H')),

$$\text{Rep}(\tilde{R}) \geq \left(1 - \frac{1}{e}\right) \cdot \text{OPT}_{\text{phân bố}}^{(\text{cụm})}.$$

Proof. Bước 1 — bảo chứng cục bộ trong từng cụm. Cố định cụm i . Vòng lặp **while** trong Bước 2 của thuật toán sửa đổi duy trì bảng Cov_i trên $\Omega = C_i$ đúng theo quy tắc của Bổ đề 1, và chọn $r^* = \arg \max_{r \in C_i \setminus \tilde{R}_i} \Delta_i(r)$ — đúng $\arg \max$ lợi ích biên toàn cục trong phạm vi C_i , thêm đúng một phần tử mỗi bước. Áp dụng lập luận của Định lý 1 với $R, \text{Rep}, \text{Cov}, m$ thay bằng $C_i, \text{Rep}_i, \text{Cov}_i, \text{target}_i$:

$$\text{Rep}_i(\tilde{R}_i) \geq \left(1 - \frac{1}{e}\right) \text{Rep}_i^*, \quad \forall i = 1, \dots, M_c. \quad (\dagger)$$

Bước 2 — gộp qua các cụm bằng Định lý 7. Vì $\{C_1, \dots, C_{M_c}\}$ (Bước 1 của thuật toán, không đổi so với bản gốc) là một phân hoạch rời nhau, phủ kín R — **cùng cấu trúc toán học** với $\{R^1, \dots, R^S\}$ ở Thuật toán 2.5, chỉ khác nguồn gốc hình thành (gom cụm dữ liệu thay vì tiêu chí phân tầng) — Định lý 7 áp dụng nguyên vẹn,

không cần chứng minh lại, chỉ cần thay ký hiệu $R^s \rightarrow C_i$, $p_s \rightarrow q_i$:

$$\text{Rep}(\tilde{R}) \geq \sum_{i=1}^{M_c} q_i \text{Rep}_i(\tilde{R}_i) \stackrel{(\dagger)}{\geq} \left(1 - \frac{1}{e}\right) \sum_{i=1}^{M_c} q_i \text{Rep}_i^* = \left(1 - \frac{1}{e}\right) \text{OPT}_{\text{phân bố}}^{(\text{cụm})}. \quad \square$$

Nhận xét 9. Bước 2 của thuật toán gốc (tính xác suất chọn cụm, bảng alias) và Bước 3 gốc (chọn cụm ngẫu nhiên đến khi đủ số lượng) đã bị **loại bỏ hoàn toàn** khỏi thuật toán sửa đổi, thay bằng việc duyệt tuần tự `for` $i = 1 \rightarrow M_c$ qua **mọi** cụm — đây chính là điều kiện để $\{C_i\}$ đóng vai trò một phân hoạch *phủ kín* R trong chứng minh trên; nếu giữ lại cơ chế chọn cụm ngẫu nhiên của bản gốc (khiến một số cụm bị bỏ qua hoàn toàn), giả thiết “phủ kín” của Định lý 7 sẽ không còn thỏa, và Bước 2 của chứng minh trên sẽ sụp đổ ngay từ dòng đầu.

5 Thuật toán 2.8 (sửa đổi) — Lấy mẫu tham lam thay thế lấy mẫu quả cầu tuyết

Ý tưởng

Bản gốc giới hạn tập ứng viên tại mỗi sóng lan truyền chỉ gồm các luật liên kết trực tiếp với Frontier hiện tại qua thực thể chung ($\text{Referrals}(R_i)$), và tiêu chí cắt giảm nhánh (TopC) dựa trên độ tương đồng/bậc kết nối chứ không phải lợi ích biên đối với Rep . Tuy kiểm tra trùng lặp của bản gốc **đã là toàn cục** (so với $\tilde{R}$ hiện có, không chỉ cục bộ) — điểm cộng duy nhất so với Thuật toán 2.6 — nhưng việc giới hạn ứng viên theo cấu trúc lan truyền vẫn khiến luật có lợi ích biên toàn cục lớn nhất có thể không được xét đến. Phiên bản sửa bỏ hoàn toàn chỉ mục nghịch đảo và cơ chế lan truyền theo sóng, thay bằng vòng lặp tham lam tất định trên toàn bộ $R \setminus \tilde{R}$.

Nhận xét 10. Khác với Thuật toán 2.5/2.7, Thuật toán 2.8 **không có cấu trúc phân hoạch** rời nhau phủ kín R — nó là một quá trình lan truyền tuần tự mở rộng dần từ hạt giống. Do đó không có “định lý gộp” nào trong khung lý thuyết để tái sử dụng, và thuật toán sau khi sửa buộc phải quy về GreedyFKGS, tương tự tình huống của Thuật toán 2.3 và 2.6.

Các bước thực hiện

Bước 1. Khởi tạo: Đặt $\tilde{R} = \emptyset$; khởi tạo bảng $\text{Cov}(r) = 0$ với mọi $r \in R$; xác định $n = |R|$ và ngân sách $\text{target} = \lceil \theta \cdot n \rceil$. (Bỏ hoàn toàn bước xây chỉ mục nghịch đảo EntityIndex và bước chọn hạt giống ban đầu R_{seed} của bản gốc.)

Bước 2. Vòng lặp chọn tham lam (target vòng): Tại mỗi vòng lặp, tính lợi ích biên $\Delta(r)$ cho **mọi** ứng viên còn lại $r \in R \setminus \tilde{R}$ (không giới hạn theo $\text{Referrals}(R_i)/\text{Frontier}$ như bản gốc), chọn $r^* = \arg \max_r \Delta(r)$ (không dùng tiêu chí TopC theo similarity/degree), thêm vào $\tilde{R}$, cập nhật bảng Cov toàn cục.

Bước 3. Xây dựng FKGS: Suy ra $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$ từ $\tilde{R}$ theo cấu trúc FKG gốc. (Bỏ hoàn toàn Bước 4 gốc — tái gieo mầm khi mạng cạn kiệt — vì không còn khái niệm “mạng lan truyền cạn kiệt” khi tập ứng viên luôn là toàn bộ $R \setminus \tilde{R}$.)

Thuật toán

Độ phức tạp

$$T(n) = O(\text{target} \cdot n) = O(\theta \cdot n^2),$$

tăng đáng kể so với $O(n(d + \log c))$ của bản gốc — mất toàn bộ lợi thế chi phí thấp của việc lan truyền qua chỉ mục nghịch đảo cục bộ, cùng loại đánh đổi đã ghi nhận ở Thuật toán 2.6.

Lý lẽ bảo chứng Submodular

Định lý 5 (Bảo chứng của Thuật toán 2.8 sửa đổi). Gọi $\tilde{R}_0 = \emptyset, \tilde{R}_1, \dots, \tilde{R}_{\text{target}}$ là dãy tập hợp sinh bởi Thuật toán 6 với $\text{target} = \lceil \theta n \rceil$. Khi đó $\text{Rep}(\tilde{R}_{\text{target}}) \geq (1 - 1/e) \cdot \text{OPT}$.

Proof. Đối chiếu dòng lệnh. Thuật toán sửa đổi khởi tạo $\text{Cov} \equiv 0$ trên $\Omega = R$ (không còn EntityIndex , Visited , Frontier như bản gốc) và cập nhật $\text{Cov}(r') \leftarrow \max(\text{Cov}(r'), \text{Sim}(r', r^*))$ với mọi $r' \in R$ sau mỗi lần thêm r^* — đúng quy tắc của

Algorithm 6 Lấy mẫu tham lam đảm bảo tính dưới mô-đun – thay thế SBFKGS (sửa đổi)

Require: $FKG(V, L, A, B, R)$, θ (tỉ lệ mẫu)

Ensure: $FKGS = (\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}, \tilde{R})$

```

1:  $\tilde{R} \leftarrow \emptyset$  ▷ Khởi tạo tập  $\tilde{R}$ 
2:  $\text{Cov}(r) \leftarrow 0$  với mọi  $r \in R$  ▷ Khởi tạo bảng độ phủ
3:  $n \leftarrow |R|$ ;  $\text{target} \leftarrow \lceil \theta \cdot n \rceil$  ▷ Bỏ chỉ mục nghịch đảo EntityIndex và hạt giống  $R_{\text{seed}}$  của bản gốc
4: while  $|\tilde{R}| < \text{target}$  do
5:   for each  $r \in R \setminus \tilde{R}$  do
6:      $\Delta(r) \leftarrow \frac{1}{n} \sum_{r' \in R} [\max(\text{Cov}(r'), \text{Sim}(r', r)) - \text{Cov}(r')]$  ▷ Lợi ích biên toàn cục –
       KHÔNG giới hạn theo Referrals
7:   end for
8:    $r^* \leftarrow \arg \max_{r \in R \setminus \tilde{R}} \Delta(r)$  ▷ Chọn theo giá trị Rep – KHÔNG dùng tiêu chí
       similarity/degree
9:    $\tilde{R} \leftarrow \tilde{R} \cup \{r^*\}$  ▷ Thêm luật  $r^*$  vào tập mẫu
10:   $\text{Cov}(r') \leftarrow \max(\text{Cov}(r'), \text{Sim}(r', r^*))$  với mọi  $r' \in R$  ▷ Cập nhật độ phủ toàn cục
11: end while
12: return  $\tilde{R}$  (và  $\tilde{V}, \tilde{L}, \tilde{A}, \tilde{B}$  suy ra từ  $\tilde{R}$ ) ▷ Xây dựng  $FKGS$  theo cấu trúc FKG gốc

```

Bổ đề 1. Do đó $\Delta(r) = \text{Rep}(\tilde{R} \cup \{r\}) - \text{Rep}(\tilde{R})$, và dòng “ $r^* \leftarrow \arg \max_{r \in R \setminus \tilde{R}} \Delta(r)$ ” lấy $\arg \max$ trên **toàn bộ** $R \setminus \tilde{R}$ — không còn giới hạn bởi $\text{Referrals}(R_i)$ (tập ứng viên giới hạn theo kết nối thực thể chung ở bản gốc) hay tiêu chí TopC (similarity/degree, không phải lợi ích biên đối với Rep). Mỗi bước thêm đúng một phần tử. Cả hai điều kiện (i)–(ii) được thỏa.

Áp dụng Bổ đề 2 và Định lý 5. Lập luận hoàn toàn tương tự Bước 2–3 của chứng minh Định lý 1 (và Định lý 3): dãy $(\tilde{R}_t)$ trùng với dãy sinh bởi thuật toán tham lam tổng quát trên (R, target) theo Bổ đề 2, nên

$$\text{Rep}(\tilde{R}_{\text{target}}) \geq \left(1 - \frac{1}{e}\right) \cdot \text{OPT}. \quad \square$$

Nhận xét 11. Khác với Thuật toán 2.5/2.7, tập $\{C_1, \dots\}$ hay cấu trúc lan truyền $(\text{Frontier}_w)_{w \geq 0}$ của Thuật toán 2.8 gốc **không tạo thành một phân hoạch rời nhau, phủ kín R tại một thời điểm cố định** (các sóng lan truyền chồng lấn theo thời gian, không theo không gian), nên Định lý 7 **không áp dụng được** cho ngữ cảnh này dù có sửa cách chọn nội bộ. Đây là lý do Thuật toán 2.8, cũng như 2.3 và 2.6, buộc phải quy hoàn toàn về GreedyFKGS (Định lý 5) để có bảo chứng $(1 - 1/e) \cdot \text{OPT}$, thay vì giữ được một phần đặc trưng thiết kế riêng như trường hợp 2.5/2.7.

Hướng mở (không thuộc phạm vi chương hiện tại): nếu muốn giữ đặc trưng lan truyền cục bộ của Thuật toán 2.8 mà vẫn có một dạng bảo chứng nào đó, có thể tham khảo lý thuyết tối ưu hóa dưới mô-đun dưới ràng buộc tổng quát hơn ràng buộc cardinality — cụ thể là ràng buộc dạng matroid hoặc ràng buộc khả đạt (reachability constraint) trên đồ thị. Đây là một hướng mở rộng lý thuyết đáng kể, nằm ngoài phạm vi khung lý thuyết hiện có của luận án, có thể nêu như một hướng phát triển trong tương lai.